

ESPRIT — POC Vérification IA des dossiers d'admission

État d'avancement du projet

Réunion de validation — mardi 11 août 2026

Dépôt : github.com/ab2sfaxii/poc-admission-esprit (branche main)

Ce document résume ce qui a été réalisé, ce qui reste à faire, les points flous rencontrés pendant le développement, les données que l'encadrante doit fournir pour la suite, et les questions à lui poser lors de la réunion de validation.

1. Ce qui a été réalisé

1.1 Sprint 1 — Prétraitement et OCR (terminé)

- Pipeline OpenCV : contraste adaptatif (CLAHE), débruitage, correction d'inclinaison, recadrage, redimensionnement.
- OCR Tesseract multilingue (français, arabe, anglais).
- Validé sur documents synthétiques et sur de vrais documents tunisiens (CIN et acte de naissance réels).

1.2 Sprint 2 — Classification et extraction (terminé)

- Classification par règles pondérées pour les 5 types de documents, avec mots-clés arabes pour la carte d'identité.
- 5 extracteurs spécialisés respectant un contrat JSON commun.
- Extraction positionnelle avancée (texte en écriture arabe de droite à gauche, tableaux français) pour les documents réels dont la mise en page ne suit pas un simple format "Libellé : valeur".
- Seconde passe OCR ciblée (zoom) sur les zones illisibles en une seule passe globale.

1.3 Début du Sprint 3 (partiel)

- Vérification de cohérence d'identité entre documents (nom/prénom) - fonctionnelle, testée.
- Module de génération de questions d'entretien : profil candidat, prompt, appel LLM - code complet et testé avec une vraie clé API. L'appel échoue proprement (message d'erreur clair affiché dans l'interface) faute de crédit sur le compte OpenAI utilisé pour le test (erreur "insufficient_quota") - le code fonctionne, seul le crédit API manque.

1.4 Interface et qualité

- Interface Streamlit : un emplacement de dépôt par type de document, détection des documents mal catégorisés, mise en forme ESPRIT (logo, couleurs).
- 38 tests automatisés, tous passants.
- Dépôt Git dédié au projet (indépendant du dépôt d'équipe PIWeb), historique de commits complet.

2. Ce qui n'a pas été fait (reste du Sprint 3)

Fonctionnalité	État
Score de complétude global du dossier	Non implémenté - barème et seuils de statut non définis
Vérification des années universitaires (doublons, années manquantes, erreurs de classement)	Non implémenté
Vérification du niveau académique conforme	Non implémenté - critères non définis
Détection de documents dupliqués	Non implémenté
Génération réelle de questions d'entretien	Code testé avec une vraie clé - bloqué par un compte OpenAI sans crédit (erreur "insufficient_quota"), pas par le code
Classifieur par Machine Learning (évolution proposée §4.6 du rapport)	Non implémenté - classification 100% par règles actuellement

3. Points flous rencontrés concrètement pendant le développement

- La qualité d'image change radicalement les résultats : l'OCR est très fiable sur des scans propres mais nettement moins sur de vraies photos (éclairage inégal, angle, reflets).
- Seulement 2 vrais documents ont pu être testés (une CIN et un acte de naissance), appartenant à deux personnes différentes - aucun dossier candidat réel complet et cohérent n'a été fourni pour les tests.
- La comparaison de noms entre écritures différentes (arabe / latin) n'est pas gérée - limite technique assumée, à traiter si plusieurs nationalités doivent être couvertes.
- Aucun barème chiffré n'existe pour le score de complétude (poids par type d'anomalie, seuils "Complet"/"À vérifier"/"Incomplet").
- Les nationalités à couvrir dans le périmètre du POC ne sont pas définies.

4. Données que l'encadrante doit fournir pour la suite

Donnée	Pourquoi
Documents réels anonymisés par type (CIN, acte de naissance, bac, licence, relevés)	Le pipeline n'a été validé que sur 2 vrais documents ; la diversité de format/qualité change fortement les résultats
Dossiers candidats complets (valides ET volontairement invalides)	Indispensable pour tester la cohérence, les doublons, le niveau académique - impossible avec des documents isolés
Vérité terrain (transcription de référence) sur un échantillon	Pour mesurer objectivement le taux d'erreur OCR, pas seulement à l'œil
Barème chiffré du score de complétude	Nécessaire pour coder le Sprint 3 - ne peut pas être deviné
Définition du niveau académique conforme	Quels diplômes/parcours sont acceptés exactement
Nationalités prioritaires à couvrir	Change fortement l'ampleur du travail (déjà vécu avec l'arabe)
Crédit sur un compte API LLM (clé déjà testée, compte à budget épuisé)	Le module a été testé et fonctionne : seul le crédit du compte OpenAI utilisé bloque son activation (erreur "insufficient_quota")
Cadre légal sur l'usage de vrais documents	Condition préalable à tout test sur données réelles

5. Questions à poser à l'encadrante demain

- 5.1. L'état actuel (Sprint 1, Sprint 2, début de Sprint 3) correspond-il à ce qui était attendu à ce stade ?
- 5.2. Peut-on obtenir des documents réels anonymisés (et des dossiers complets, valides et invalides) pour la suite des tests ?
- 5.3. Quelles nationalités doivent être prioritairement couvertes ?
- 5.4. Quel est le barème attendu pour le score de complétude, et les seuils de statut du dossier ?
- 5.5. Le module de questions d'entretien est testé et fonctionnel, mais bloqué par un compte OpenAI sans crédit - peut-on obtenir un compte/une clé avec du crédit disponible ?
- 5.6. Le calendrier du Sprint 3 (05/08 - 24/08/2026 selon le rapport) est-il toujours d'actualité compte tenu du retard pris sur les données de test ?
- 5.7. Quelle grille de critères sera utilisée pour évaluer le POC à la soutenance ?

6. Démonstration prévue demain

- Dossier complet et cohérent (5/5 documents, identité cohérente, extraction réussie).
- Détection d'un document déposé dans le mauvais emplacement.
- Détection d'une incohérence d'identité entre deux documents.
- Aperçu du module de génération de questions d'entretien : appel réel à l'API testé, échec propre et message clair affiché faute de crédit sur le compte OpenAI utilisé - preuve que le module est prêt, indépendamment du blocage de facturation.

Document préparé pour la réunion de validation du 11 août 2026, à partir de l'état réel du dépôt (commit le plus récent : Sprint 3 - cohérence d'identité et génération de questions d'entretien).