

ESPRIT — POC Vérification IA des dossiers d'admission

Mise à jour de l'état d'avancement

Sprint 3 — suite de la réunion du 11 août 2026

Préparé pour la réunion de validation du 3 septembre 2026
Dépôt : github.com/ab2sfaxii/poc-admission-esprit (branche main)

Ce document met à jour *État d'avancement du projet* (11 août 2026) et *Rapport technique détaillé* (11 août 2026) : il liste ce qui a été réalisé depuis cette réunion, ce qui reste bloqué en l'absence de réponse de l'encadrante sur les points déjà soulevés le 31 juillet, et ce qui est prêt pour la démonstration.

1. Ce qui a été réalisé depuis le 11 août 2026

Le tableau « Ce qui n'a pas été fait » du rapport du 11 août listait 6 lignes. 4 sont maintenant résolues :

Fonctionnalité (Sprint 3)	État au 11 août	État au 3 septembre
Score de complétude global du dossier	Non implémenté	Implémenté — verification/completeness_score.py. Barème par défaut documenté et ajustable (présence 50% / extraction 30% / cohérence 20%), en l'absence de barème officiel.
Vérification des années universitaires	Non implémenté	Implémenté — verification/academic_years_checker.py (doublons, années manquantes, cohérence avec la licence).
Détection de documents dupliqués	Non implémenté	Implémenté — verification/duplicate_document_checker.py.
Génération réelle de questions d'entretien	Bloqué (compte OpenAI sans crédit)	Débloqué — Groq et Google Gemini ajoutés comme fournisseurs gratuits (sans carte bancaire), en plus d'OpenAI.
Vérification du niveau académique conforme	Non implémenté, critères non définis	Toujours non implémenté — critères toujours non définis (cf. §3).
Classifieur par Machine Learning	Non implémenté (évolution proposée)	Inchangé — hors périmètre du POC.

Complément découvert pendant l'implémentation du score de complétude

L'extension de **identity_checker.py** à la date de naissance (comparaison CIN / acte de naissance, en plus du nom) a aussi été ajoutée : c'était un gain direct, sans barème à inventer (une date n'a pas de variante légitime, contrairement à un nom). Détecte le scénario de démonstration *09_dates_incoherentes_fejjari_hedi*.

Validation à grande échelle (nouveau)

Chaque nouvelle vérification a été mesurée avec **tests/evaluate_pipeline.py** sur un échantillon de 105 dossiers (15 par type d'anomalie) du jeu de 1000 dossiers synthétiques avec vérité terrain (data/samples_dataset/) — pas seulement sur les 60 tests unitaires :

Module	Anomalie ciblée	Résultat mesuré
completeness_score	document_bac_manquant (50 dossiers)	100% détecté (statut « documents_manquants »), 0% de faux positifs sur les 6 autres catégories.
academic_years_checker	annee_universitaire_dupliee, annee_licence_incoherente	100% détecté sur les 2 catégories ciblées, ~100% de cohérence jugée correcte ailleurs.
identity_checker	nom_mal_orthographie, identite_releve_inversee	Inchangé par l'ajout de la date (le dataset des 1000 dossiers ne varie pas la date de naissance) — toujours détecté comme avant l'ajout.

Module	Anomalie ciblée	Résultat mesuré
duplicate_document_checker	(aucun scénario dédié dans ce dataset)	0% de faux positifs sur les 7 catégories, y compris entre relevés d'années différentes qui se ressemblent structurellement.

Le rapport JSON détaillé de cette évaluation est écrit dans data/reports/ à chaque exécution (non versionné).

2. Une anomalie étudiée mais délibérément non implémentée

Le jeu de 1000 dossiers contient une 7e catégorie, **moyenne_incoherente_avec_mention** (50 dossiers) : la mention du diplôme de licence est censée être incohérente avec les moyennes des relevés. Avant de coder une règle, la moyenne par mention a été mesurée statistiquement sur les 700 dossiers cohérents du dataset (script d'analyse ponctuel, sans OCR - directement sur la vérité terrain) :

Mention (licence)	Moyenne L3 observée	Chevauchement avec la mention voisine
Passable	9.59 – 11.45	—
Assez Bien	10.47 – 13.40	se chevauche avec Passable et Bien
Bien	12.46 – 15.91	se chevauche avec Assez Bien et Très Bien
Très Bien	15.09 – 18.58	se chevauche avec Bien

Les plages se chevauchent sur les 700 dossiers volontairement cohérents : un seuil fixe (ex. « Bien = moyenne ≥ 14 ») déclencherait donc de **fausses alertes sur des dossiers réellement cohérents**, ce qui va à l'encontre de l'exigence de fiabilité déjà tenue par les autres vérifications (0% de faux positifs mesurés). Cette anomalie n'a donc pas été codée : c'est le même type de décision métier que le « niveau académique conforme » (rapport §9), qui nécessite un barème officiel plutôt qu'un seuil inventé.

3. Ce qui reste bloqué — inchangé depuis le 31 juillet

Les points suivants, déjà soulevés dans *Points à clarifier avec l'encadrante* (31 juillet) et *État d'avancement* (11 août), n'ont toujours pas de réponse. Ils ne peuvent pas être devinés sans risquer un développement à refaire :

- **Barème officiel du score de complétude** — un barème par défaut du POC est utilisé en attendant (documenté et ajustable dans config/settings.py), mais n'a pas été validé par l'encadrante.
- **Définition du « niveau académique conforme »** — quels diplômes/parcours sont acceptés, seuils de moyenne le cas échéant.
- **Nationalités prioritaires à couvrir** — le système ne gère aujourd'hui que des documents tunisiens (CIN en arabe/français).
- **Documents réels anonymisés et dossiers candidats complets** (valides ET volontairement invalides) — toujours seulement 2 vrais documents testés, tout le reste du Sprint 3 est validé sur données 100% synthétiques.
- **Cadre légal / RGPD** sur l'usage de vrais documents, même anonymisés.

4. Prêt pour la démonstration

En plus des points déjà démontrés le 11 août (dossier complet et cohérent, document mal catégorisé, incohérence d'identité, appel LLM), la démonstration peut maintenant couvrir :

- Détection d'un **document manquant** avec score de complétude chiffré (dossier de démo 07_document_manquant_bouazizi_sami, score 93%, statut « Documents manquants »).
- Détection d'une **date de naissance incohérente** entre CIN et acte de naissance (dossier 09_dates_incoherentes_fejjari_hedi).
- Détection d'un **relevé d'année manquant** dans le parcours L1→L2→L3→M1 (dossier 08_annees_incoherentes_werghi_nadia).
- Détection d'un **document dupliqué** (dossier 11_document_duplique_sassi_yassine).
- **Génération réelle de questions d'entretien**, fonctionnelle sans frais avec Groq (plus de blocage « insuffisant_quota »).
- Le **quiz de pré-entretien** côté espace candidat, avec score remonté à l'enseignant.

Document préparé à partir de l'état réel du dépôt au 3 septembre 2026 (commit le plus récent : Sprint 3 - score de complétude et cohérence des dates de naissance).