

ESPRIT — POC Vérification IA des dossiers d'admission

Document de passation

Ce qui est fait, ce qu'il reste à faire

Préparé le 12 septembre 2026, pour transfert au binôme
Dépôt : github.com/SiwarSlimi1/stage_d-ete_esprit (branche main)

Ce document résume l'état réel du projet pour permettre une reprise rapide : ce qui est terminé et testé, ce qui reste à faire (et pourquoi), comment lancer le projet, et les points d'attention à connaître avant de continuer.

1. Démarrage rapide

Cloner le dépôt, puis :

```
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt

# Tesseract OCR doit etre installe separement (langues fra, ara, eng)
# Si le binaire n'est pas dans le PATH, definir TESSERACT_CMD

streamlit run app.py
```

Pour tester sans documents réels (confidentialité, cf. §5) :

```
python -m tests.sample_documents # 5 documents d'exemple
python -m tests.generate_synthetic_dataset # 11 dossiers de demo
pytest -v # 69 tests, tous passants
```

Dans Streamlit, choisir « Dossier de démonstration » pour parcourir les 11 dossiers synthétiques (5 valides, 6 avec anomalie volontaire) sans rien déposer manuellement.

2. Ce qui est fait (terminé et testé)

Sprint 1 — Prétraitement et OCR

- preprocessing/ : contraste adaptatif (CLAHE), débruitage, correction d'inclinaison, redimensionnement.
- ocr/ : interface Tesseract multilingue (français, arabe, anglais), regroupement positionnel des mots, seconde passe OCR ciblée (zoom) sur zones dégradées.

Sprint 2 — Classification et extraction

- classification/rules_classifier.py : classification par mots-clés pondérés, 5 types de documents, mots-clés arabes pour la CIN.
- extraction/ : 5 extracteurs spécialisés (cin, acte_naissance, bac, diplome_licence, releve_notes), contrat JSON commun (document_type, fields, missing_fields, warnings, extraction_status).

Sprint 3 — Vérification, complétude, entretien

Fonctionnalité	Fichier(s)	État
Cohérence d'identité (nom, prénom, date de naissance)	verification/identity_checker.py	Fait — inversion nom/prénom et divergence de date détectées
Cohérence des années universitaires	verification/academic_years_checker.py	Fait — doublons, années manquantes, cohérence avec la licence
Détection de documents dupliqués	verification/duplicate_document_checker.py	Fait
Score de complétude global du dossier	verification/completeness_score.py	Fait — barème par défaut ajustable dans config/settings.py (voir §3)

Fonctionnalité	Fichier(s)	État
Génération de questions d'entretien (Module 2)	interview/question_generator.py	Fait — 3 fournisseurs LLM (Groq, Gemini, OpenAI)
Quiz de pré-entretien (QCM, espace candidat)	pages/1_Espace_Candidat.py	Fait
Entretien simulé (questions ouvertes + retour formatif)	pages/1_Espace_Candidat.py, interview/question_generator.py	Fait — jamais de verdict d'admission (voir §4)

Qualité et validation

- 69 tests automatisés (pytest), tous passants.
- tests/evaluate_pipeline.py : évaluation à grande échelle sur un jeu de 1000 dossiers synthétiques avec vérité terrain (data/samples_dataset/) — chaque vérification mesurée à 100% de détection sur son anomalie ciblée, 0% de faux positifs ailleurs.
- Interface Streamlit complète : espace enseignant (app.py) et espace candidat (pages/1_Espace_Candidat.py), thème ESPRIT (ui_common.py).

3. Ce qui reste à faire

3.1 Bloqué en attendant une décision de l'encadrante

Ces points ne peuvent pas être codés sans risquer de tout refaire — ils nécessitent une réponse de l'encadrante (déjà demandée à plusieurs reprises, cf. Points_a_clarifier_Encadrante.pdf dans le dépôt) :

- **Barème officiel du score de complétude** — un barème par défaut du POC est utilisé en attendant (config/settings.py : COMPLETENESS_WEIGHT_PRESENCE/EXTRACTION/COHERENCE), documenté comme provisoire.
- **Définition du « niveau académique conforme »** — quels diplômes/parcours sont acceptés, seuils de moyenne le cas échéant. Sans ça, impossible d'ajouter une vérification automatique du niveau académique (le champ « résultat » VALIDE/AJOURNÉ est déjà extrait et visible, mais aucune règle de décision n'est codée).
- **Nationalités prioritaires à couvrir** — le système ne gère aujourd'hui que des documents tunisiens (CIN en arabe/français). Couvrir d'autres nationalités demande un travail conséquent (vécu avec l'arabe seul).
- **Documents réels anonymisés et dossiers candidats complets** (valides ET volontairement invalides) — tout le Sprint 3 est validé sur données 100% synthétiques (data/dossiers_synthétiques/, data/samples_dataset/), faute de mieux.
- **Cadre légal / RGPD** sur l'usage de vrais documents, même anonymisés.

3.2 À vérifier techniquement

- **Fournisseur Groq** — le modèle par défaut a changé le 12/09/2026 suite à un changement côté Groq (« llama-3.3-70b-versatile » est passé en accès payant Enterprise). Remplacé par « openai/gpt-oss-20b » (toujours gratuit d'après la documentation Groq), mais **pas encore testé en direct avec une vraie clé API** dans cet environnement — à confirmer en premier avant de démontrer la génération de questions.
- **Anomalie « moyenne incohérente avec la mention »** (jeu de 1000 dossiers) — étudiée puis délibérément laissée de côté : l'analyse statistique du dataset montre que les plages de moyenne se chevauchent entre mentions voisines du diplôme, un seuil fixe créerait des faux positifs. Ne pas coder de règle sans barème officiel (même logique que le niveau académique conforme).

3.3 Optionnel / hors périmètre du POC

- Classifieur par Machine Learning (évolution proposée) — la classification 100% par règles actuelle fonctionne bien sur le périmètre testé ; pas nécessaire pour un POC.
- Translittération arabe/français pour la comparaison de noms (identity_checker.py) — limite documentée, non implémentée.

4. Points d'attention avant de reprendre

- **Confidentialité** — ne jamais committer de vrais documents (CIN, actes de naissance, etc.), même anonymisés, sans confirmation explicite du cadre légal par l'encadrante (cf. §3.1). Le .gitignore exclut déjà les .jpg/.jpeg dans data/samples/.
- **data/samples/*.png se régénèrent à chaque exécution des tests** (rendu de texte non déterministe) et apparaissent comme modifiés dans `git status` après un `pytest` — pas une vraie modification, à ignorer ou restaurer avec `git checkout -- data/samples/`.

- **Le principe « aucune décision d'admission automatisée » (rapport §1.5) est non négociable** dans ce projet — répété dans tout le code et les rapports. L'entretien simulé (§2, espace candidat) a justement été conçu pour rester purement formatif : jamais de verdict de type « tu es capable d'obtenir cette spécialité », jamais transmis à l'enseignant. À respecter pour toute nouvelle fonctionnalité touchant à l'entretien ou à l'évaluation du candidat.
- **data/samples_dataset/** (jeu de 1000 dossiers, ~150 Mo d'images) n'est pas versionné — seul manifest.jsonl (vérité terrain) l'est. Régénérer avec ``python -m tests.generate_dataset_images --from-manifest`` avant de lancer `tests/evaluate_pipeline.py`.

5. Structure du dépôt

```
config/ Parametres (langues OCR, chemin Tesseract, bareme completude)
preprocessing/ Pretraitement OpenCV
ocr/ Interface Tesseract
classification/ Classification par regles
extraction/ 5 extracteurs specialises + contrat JSON commun
verification/ Coherence entre documents + score de completude (Sprint 3)
interview/ Questions d'entretien + entretien simule (Sprint 3, Module 2)
models/ Structures de donnees (Document, ExtractionResult, CandidateFile)
tests/ 69 tests unitaires + generateurs de jeux de donnees synthetiques
app.py Interface Streamlit - espace enseignant
pages/1_Espace_Candidat.py Interface Streamlit - espace candidat
ui_common.py Theme, composants et LLM partages entre les deux espaces
```

README.md contient le détail complet de chaque commande. Rapport_Detaille_Projet.pdf (racine du dépôt) donne le contexte complet du stage, section par section.

Document préparé à partir de l'état réel du dépôt au 12 septembre 2026 (dernier commit : correction de la dépendance httpx et des modèles Groq).