

ESPRIT — POC Vérification IA des dossiers d'admission

Points à clarifier avec l'encadrante académique

Réunion du vendredi 31 juillet 2026

Document préparatoire — Sprint 1 & 2 réalisés, clarifications nécessaires avant Sprint 3

Ce document liste, par ordre de priorité, les données à obtenir et les décisions métier à faire valider auprès de l'encadrante afin de pouvoir poursuivre le développement (vérification de cohérence, score de complétude, génération de questions d'entretien) et de tester le système sur des bases réellement représentatives plutôt que sur des documents synthétiques.

1. Documents et données de test à fournir

Point le plus urgent : à ce stade, le pipeline n'a été validé que sur des documents synthétiques générés pour les tests, et sur une seule pièce d'identité réelle. La qualité et la diversité des documents changent radicalement les résultats (vérifié empiriquement pendant le développement).

1.1 Documents bruts, par type

Type de document	Ce qui est demandé
CIN / pièce d'identité	Plusieurs exemplaires anonymisés (tunisiens et, si dans le périmètre, étrangers), en qualités variées : scan propre ET photo de téléphone.
Acte de naissance	Plusieurs exemplaires - le format varie déjà d'un gouvernorat tunisien à l'autre, donc davantage encore d'un pays à l'autre.
Diplôme du baccalauréat	Plusieurs années, filières (sciences, économie, lettres, technique...) et mentions, pour couvrir les variations de mise en page.
Diplôme de licence	Plusieurs spécialités et établissements - chaque université a son propre template de diplôme.
Relevés de notes	Pour chaque année (1, 2, 3, éventuellement M1), de plusieurs facultés/instituts différents - le document le plus hétérogène en pratique.

1.2 Dossiers candidats complets (pas des documents isolés)

Nécessaires pour tout le Sprint 3 (vérification de cohérence, score de complétude, détection de doublons) : il faut des jeux de documents appartenant à un même candidat, pas seulement des documents isolés.

- Des dossiers valides et complets (cas nominal).
- Des dossiers volontairement invalides, construits exprès pour tester chaque règle : incohérence d'identité entre deux documents (ex. date de naissance différente), relevé d'une année manquant, document dupliqué, document déposé dans la mauvaise catégorie, niveau académique non conforme.

Sans ces cas négatifs, on ne peut prouver que le système lit les documents - pas qu'il détecte réellement les anomalies.

1.3 Vérité terrain (ground truth)

Pour au moins un échantillon de documents : la transcription correcte attendue (texte exact, ou au minimum les champs clés - nom, prénom, date, notes...). Indispensable pour mesurer objectivement le taux d'erreur OCR et la précision d'extraction, comme le prévoit le rapport (§7.1, tests OCR). Sans cette référence, on ne peut que constater empiriquement que "ça a l'air bon", sans le démontrer.

2. Règles métier à faire préciser

Ces décisions sont nécessaires pour coder Sprint 3 - elles ne peuvent pas être devinées ou supposées sans risquer de devoir tout refaire.

2.1. Quelles nationalités sont vraiment prioritaires pour ce POC ?

Pourquoi : Tunisienne seule, ou plusieurs (marocaine, algérienne, libyenne, française, subsaharienne...) ? Ça change radicalement l'ampleur du travail : gérer l'arabe en plus du français a déjà demandé un travail conséquent pour un seul type de document (la CIN).

2.2. Quelle est la définition précise du "niveau académique conforme" ?

Pourquoi : Quels diplômes/parcours sont acceptés exactement (licence complète, M1, BTS/DUT équivalent...) et lesquels sont refusés ?

2.3. Quelle est la liste exhaustive des documents obligatoires ?

Pourquoi : Le rapport en cite 5, mais existe-t-il des variantes ou pièces optionnelles selon le profil du candidat ?

2.4. Comment traiter les cas particuliers de cursus ?

Pourquoi : Redoublement, année de césure, changement d'université en cours de parcours - comment ne pas les confondre avec un "dossier incomplet" ?

2.5. Quel est le barème chiffré du score de complétude ?

Pourquoi : Quel poids pour un document manquant, une incohérence mineure, une incohérence majeure ? À partir de quel score : "Complet" / "À vérifier manuellement" / "Incomplet" ?

3. Module 2 — génération de questions d'entretien (Sprint 3)

3.1. Quel LLM utiliser et avec quel accès ?

Pourquoi : GPT via quelle API exactement ? Qui fournit la clé et prend en charge le coût des appels ?

3.2. Existe-t-il un budget/quota alloué pour les appels API ?

3.3. A-t-on des exemples réels de questions d'entretien actuelles ?

Pourquoi : Nécessaires pour calibrer le style et le niveau attendus des questions générées.

3.4. Quels champs exacts du profil candidat transmettre au LLM ?

Pourquoi : Le rapport mentionne spécialité, résultats généraux et meilleures évaluations - à confirmer précisément.

4. Cadre légal et confidentialité des données

Point rencontré concrètement pendant le développement : les documents traités contiennent des données très sensibles (numéro de CIN, empreinte digitale, adresse, filiation). Ce point conditionne tout le reste - sans réponse claire, on ne peut pas utiliser de vrais documents.

4.1. A-t-on le droit d'utiliser de vrais dossiers de candidats (même anonymisés) pour ce projet ?

4.2. Sous quelles conditions de stockage et de traitement ? (poste local uniquement, jamais sur un dépôt Git ou un service cloud ?)

4.3. Existe-t-il un cadre RGPD/éthique ESPRIT déjà documenté à respecter pour ce type de projet ?

5. Évaluation et planning

5.1. Quelle grille de critères sera utilisée pour évaluer le POC à la soutenance (taux d'extraction correct, couverture fonctionnelle, qualité du rapport JSON...) ?

5.2. Le calendrier du Sprint 3 (05/08 - 24/08/2026 selon le rapport) est-il toujours d'actualité ?

5.3. Qu'attend l'encadrante précisément pour la démonstration de vendredi : l'état actuel (Sprint 1 & 2) suffit-il, ou faut-il anticiper une partie du Sprint 3 ?

6. Tableau de suivi — à remplir pendant la réunion

Une ligne par point ci-dessus, à compléter en direct pendant l'échange avec l'encadrante.

#	Point	Réponse obtenue	Action à faire
1	1.1 Documents bruts par type		
2	1.2 Dossiers candidats complets		
3	1.3 Vérité terrain		
4	2.1 Nationalités prioritaires		
5	2.2 Niveau académique conforme		
6	2.3 Documents obligatoires		
7	2.4 Cas particuliers de cursus		
8	2.5 Barème du score de complétude		
9	3.1-3.4 Module LLM (accès, budget, exemples)		
10	4.1-4.3 Cadre légal et confidentialité		
11	5.1 Grille d'évaluation		
12	5.2 Calendrier Sprint 3		
13	5.3 Attentes pour la démo de vendredi		